


PYTHON + PANDAS + REQUESTS

PROJETO

Oscar Data Pipeline

ETL e Integração de APIs com Python

GITHUB: SARAH-BUENO

A diagram illustrating the integration of an API into a data pipeline. It features a large, light red circle in the background. In the foreground, there are two white rounded rectangles with black outlines. The top rectangle contains a red curly brace '{ }'. The bottom rectangle, which is slightly offset to the right and overlaps the bottom of the top one, contains the text 'API' in bold black font.


{ }

API

Objetivo

Construir um pipeline de dados a partir dos indicados ao Oscar de Melhor Filme Internacional, enriquecendo cada país concorrente com informações geográficas da API de países do IBGE.

O processo envolve coleta (web scraping + API REST), transformação, integração via merge e análise dos indicados por região e sub-região.



Fontes de dados

1. Indicados ao Oscar

Extraídos da Wikipédia com requests + pandas.read_html(), usando um objeto StringIO para interpretar o HTML da resposta.

```
tabelas_oscar = pd.read_html(
    StringIO(response.text)
)
oscar = pd.concat(
    tabelas_oscar[0:9],
    ignore_index=True
)
```

2. Países — API IBGE

JSON retornado pela API de países do IBGE, normalizado com pd.json_normalize() e reduzido às colunas de interesse geográfico.

```
ibge = ibge[[
    "nome.abreviado",
    "localizacao.regiao.nome",
    "localizacao.sub-regiao.nome",
    "id.ISO-3166-1-ALPHA-2",
]]
```

Limpeza e transformação

- 359 linhas e 6 colunas extraídas das tabelas da Wikipédia
- Remoção de 1 linha totalmente vazia (dropna how="all") → 358 registros
- Coluna “Ano” tratada com regex `(\d{4})` e convertida para inteiro
- 67 nomes distintos de países concorrentes identificados

`oscar.info()`

```
oscar["Ano"] = (  
    oscar["Ano"]  
        .str.extract(r"(\d{4})")  
)  
oscar["Ano"] = oscar["Ano"].astype(int)
```

Validação — países concorrentes

Foram observadas 3 situações entre os 67 valores: variações de escrita, países históricos (União Soviética, Iugoslávia...) e casos especiais (Hong Kong, França & Itália...).

Integração dos dados

Antes do merge, os nomes de países do Oscar foram comparados aos nomes da API do IBGE. Diferenças de grafia (ex.: Chéquia/Chequia, Coreia do Sul/República da Coreia) foram padronizadas com um dicionário de mapeamento.

Países históricos e casos especiais sem correspondência atual (União Soviética, Iugoslávia, Alemanha Ocidental/Oriental, Checoslováquia, Hong Kong, Taiwan, Palestina, Porto Rico, França & Itália) foram mantidos sem enriquecimento geográfico, para não gerar associações incorretas.

358

indicações no total

318

classificadas por sub-região

40


sem correspondência geográfica

Indicações por sub-região

A Europa Ocidental lidera com 80 indicações, seguida pela Europa Meridional (63). Entre as regiões não europeias, a América Latina e Caribe se destaca com 30 indicações.

```
indicados_subregiao = (  
    oscar_enriquecido  
    .groupby("sub_regiao").size()  
    .sort_values(ascending=False)  
)
```

Top sub-regiões com maior número de indicações



DESTAQUE

Participação da Europa

As quatro primeiras posições do ranking são sub-regiões europeias: Europa Ocidental, Meridional, Setentrional e Oriental — juntas, respondem por 223 das 318 indicações classificadas.

70,1%

das indicações classificadas
são de países europeus

223

Europa

46

Ásia

37

América

11

África

1

Oceania

Principais descobertas

1 Qualidade dos dados

Após a limpeza, a base ficou consistente e sem valores nulos, permitindo seguir direto para a integração e análise.

2 Concentração geográfica

A distribuição das indicações é desigual: quatro sub-regiões europeias ocupam as primeiras posições do ranking.

3 Casos especiais tratados

Países históricos e territórios sem correspondência direta na API do IBGE foram identificados e preservados sem associações incorretas.

4 Aplicação prática

O pipeline demonstra ETL de ponta a ponta: web scraping, consumo de API REST, tratamento de JSON e enriquecimento de dados com Pandas.

GITHUB: SARAH-BUENO

**Fique à vontade para
conferir o projeto completo!**

github.com/sarah-bueno

